Predicción del Riesgo de Burnout

mediante Analítica de Datos

Proyecto de Analítica de Datos - 2026

---

1. Introducción

En las últimas décadas, el bienestar laboral se ha consolidado como uno de los ejes centrales de la gestión organizacional moderna. El acelerado ritmo de trabajo, la intensificación de las demandas cognitivas y la difuminación de los límites entre la vida personal y profesional han dado lugar a un fenómeno ampliamente documentado: el burnout o síndrome de agotamiento laboral. Según la Organización Mundial de la Salud (OMS), el burnout es reconocido como un fenómeno ocupacional que afecta de manera significativa la salud física y mental de los trabajadores, con consecuencias directas sobre su desempeño, compromiso y permanencia en las organizaciones.

En este contexto, la analítica de datos y la inteligencia artificial (IA) emergen como herramientas transformadoras para el ámbito de los recursos humanos. La capacidad de procesar grandes volúmenes de información sobre comportamientos, condiciones laborales y características individuales de los empleados permite a las organizaciones anticiparse a situaciones críticas antes de que estas se materialicen. El uso de modelos predictivos en la gestión del talento humano no solo optimiza los procesos de toma de decisiones, sino que también puede contribuir activamente a la construcción de entornos de trabajo más saludables y sostenibles.

La relevancia de este análisis trasciende el ámbito puramente técnico. Desde una perspectiva organizacional, predecir con antelación el riesgo de burnout o de abandono laboral representa una ventaja estratégica considerable, ya que permite diseñar intervenciones oportunas, reducir costos asociados a la rotación de personal y fortalecer la cultura organizacional. Desde la perspectiva del trabajador, supone un avance hacia el reconocimiento de sus condiciones laborales como factores gestionables y medibles, con potencial de mejora a partir de la evidencia generada por los datos.

2. Definición del Problema

El problema central de esta investigación radica en la dificultad que enfrentan las organizaciones para identificar de manera anticipada a los empleados en riesgo de desarrollar burnout o de abandonar voluntariamente su puesto de trabajo. Históricamente, estas situaciones se detectan de forma reactiva: solo después de que el empleado ha manifestado síntomas evidentes de agotamiento o ha presentado su renuncia. Este enfoque tardío impide que las empresas implementen estrategias preventivas eficaces y genera consecuencias negativas tanto para el individuo como para la organización.

La pregunta analítica que guía este proyecto es la siguiente:

¿Es posible predecir el riesgo de burnout o abandono laboral a partir de variables laborales, demográficas y de satisfacción del empleado?

Esta pregunta cobra especial relevancia cuando se considera que las organizaciones disponen, cada vez con mayor frecuencia, de datos estructurados sobre sus empleados: género, tipo de empresa, modalidad de trabajo, nivel de cargo, carga laboral, puntuación de fatiga mental y tasa de burnout, entre otras. Sin embargo, la información disponible rara vez es aprovechada de manera analítica y sistemática para la toma de decisiones en materia de bienestar organizacional.

Predecir el burnout mediante datos no solo es técnicamente viable, sino que constituye una necesidad urgente para las organizaciones que aspiran a ser competitivas, sostenibles y éticamente responsables con su capital humano. La justificación de este enfoque descansa en tres pilares fundamentales: la disponibilidad de datos relevantes, el avance de los algoritmos de aprendizaje automático aplicados a ciencias sociales y de la salud, y el creciente reconocimiento del bienestar laboral como un factor determinante de la productividad organizacional.

3. Descripción del Problema

3.1 El Burnout Laboral

El burnout es definido en la literatura científica como un estado de agotamiento emocional, despersonalización y reducción del sentido de logro personal, derivado de la exposición prolongada a situaciones de estrés crónico en el entorno laboral (Maslach & Leiter, 1997). A diferencia del estrés agudo, el burnout es un proceso gradual que se instala silenciosamente en el trabajador, deteriorando progresivamente su capacidad de respuesta, su motivación y su salud general. Este fenómeno no distingue sectores económicos ni niveles jerárquicos, aunque existen evidencias de mayor prevalencia en roles de alta responsabilidad, trabajo remoto sin soporte adecuado y entornos laborales con escasa autonomía.

3.2 Factores Asociados al Burnout

Diversos factores han sido identificados en la investigación empírica como predictores relevantes del burnout. La carga laboral excesiva, entendida como la percepción de que las demandas del trabajo superan los recursos disponibles, es uno de los antecedentes más consistentemente documentados. La fatiga mental, por su parte, refleja el grado de agotamiento cognitivo acumulado y constituye un indicador temprano del deterioro del bienestar del trabajador.

Las características demográficas como el género y el nivel de cargo también influyen en la experiencia del burnout, aunque de manera compleja e interactuante con otros factores contextuales. Asimismo, el tipo de empresa y las condiciones bajo las cuales se presta el servicio, presencial, remota o híbrida, modulan significativamente la exposición al riesgo. La disponibilidad de trabajo remoto, en particular, ha demostrado ser un factor ambivalente: puede ser un facilitador del equilibrio vida-trabajo o, por el contrario, un agravante del aislamiento y la desdibujación de límites laborales.

3.3 Variables del Dataset

El conjunto de datos utilizado en este proyecto proviene de la plataforma Kaggle (AI Worker Risk Dataset) y contiene registros individuales de empleados con las siguientes variables:

- **ID de empleado** Identificador único numérico asignado a cada registro.
- **Rol laboral** Cargo o función que desempeña el empleado dentro de su organización. Permite segmentar el análisis por tipo de trabajo (desarrollador, analista, diseñador, etc.) y evaluar si ciertos roles son más susceptibles al burnout.
- **Años de experiencia** Tiempo acumulado del empleado en su campo profesional. Variable numérica continua que puede indicar madurez laboral, nivel de adaptación al cambio tecnológico y tolerancia a la presión.
- **Nivel educativo** Grado académico más alto alcanzado por el empleado. Variable categórica ordinal que puede correlacionarse con el tipo de herramientas de IA utilizadas, el rol desempeñado y las expectativas laborales.
- **País** de residencia o trabajo del empleado. Permite identificar diferencias culturales, normativas y contextuales en la adopción de IA y en los niveles de burnout reportados.
- **Industria** Sector económico al que pertenece la organización del empleado. Variable categórica que contextualiza el ritmo de adopción tecnológica y la intensidad de las demandas laborales según el entorno competitivo.
- **Tamaño de la empresa** Clasificación de la organización según su número de empleados (pequeña, mediana, grande). Influye directamente en la cultura organizacional, los recursos disponibles y la velocidad de implementación de herramientas de IA.
- **Tipo de trabajo remoto** Modalidad laboral del empleado: presencial, híbrido o completamente remoto. Variable de alto interés para el análisis de burnout, dado su impacto sobre el equilibrio vida-trabajo y el nivel de supervisión.
- **Tamaño del equipo** Número de personas que conforman el equipo directo del empleado. Equipos muy pequeños pueden implicar mayor carga individual; equipos muy grandes pueden generar desconexión y falta de reconocimiento.

- **Salario (USD/K)** Remuneración anual del empleado expresada en miles de dólares. Variable numérica continua que puede actuar como factor protector o de riesgo frente al burnout, dependiendo de su relación con la carga laboral percibida.

- **Herramienta primaria de IA** Herramienta de inteligencia artificial que el empleado utiliza con mayor frecuencia en su trabajo. Permite clasificar el nivel de sofisticación tecnológica y la dependencia del trabajador respecto a sistemas automatizados.

- **Herramientas de IA utilizadas por día** Número de herramientas de IA distintas que el empleado usa en una jornada laboral típica. Un valor alto puede indicar fragmentación cognitiva o sobrecarga de interfaces tecnológicas.

- **Horas con asistencia de IA diaria** Cantidad de horas diarias en que el empleado trabaja en colaboración directa con sistemas de IA. Refleja el grado de interacción humano-máquina en la rutina laboral del trabajador.

- **IA reemplaza mis tareas (%)** Porcentaje estimado de las tareas del empleado que han sido automatizadas o asumidas por herramientas de IA. Variable clave para evaluar la percepción de desplazamiento funcional y su relación con el miedo a la sustitución.

- **Etapa de adopción de IA** Fase en la que se encuentra el empleado o su organización respecto a la incorporación de IA en los procesos de trabajo. Puede ser exploratoria, en implementación o completamente integrada, y refleja el nivel de disrupción tecnológica experimentada.

- **Horas semanales de capacitación en IA** Tiempo dedicado semanalmente por el empleado a formarse en herramientas, conceptos o habilidades relacionadas con la inteligencia artificial. Un valor bajo puede indicar brechas de adaptación; un valor muy alto puede contribuir a la sobrecarga.

- **Puntuación de productividad** Indicador numérico que mide el rendimiento percibido o reportado del empleado. Permite evaluar si el uso intensivo de IA se

traduce en mayor eficiencia o si, por el contrario, genera estrés adicional sin un beneficio claro en el desempeño.

- **Puntuación de agotamiento** Medida del nivel de burnout o fatiga laboral del empleado, probablemente en una escala numérica estandarizada. Es una de las variables más relevantes del dataset y puede funcionar como variable objetivo o como predictor del riesgo de deserción.

- **Satisfacción laboral (1–5)** Valoración subjetiva del empleado sobre su experiencia general de trabajo, en una escala de 1 (muy insatisfecho) a 5 (muy satisfecho). Variable ordinal con alto poder explicativo sobre la intención de permanencia o abandono.

- **Miedo a la sustitución por IA** Percepción del empleado sobre la probabilidad de que su puesto de trabajo sea reemplazado por sistemas de inteligencia artificial. Variable psicológica de alto impacto sobre la ansiedad laboral, el agotamiento y la intención de renuncia.

- **Riesgo de deserción** Variable objetivo principal del dataset. Indica la probabilidad o categoría de riesgo de que el empleado abandone voluntariamente su organización. Puede ser binaria (sí/no) o de múltiples niveles (bajo, medio, alto), y es el fenómeno que el modelo predictivo busca anticipar.

La articulación entre estas variables permite construir un perfil multidimensional del empleado, integrando dimensiones demográficas, organizacionales y de bienestar subjetivo, lo cual enriquece significativamente la capacidad predictiva de los modelos a desarrollar.

4. Consecuencias del Problema

4.1 Impacto en los Empleados

Las consecuencias del burnout no tratado sobre los trabajadores son de carácter severo y multidimensional. A nivel físico, se asocia con trastornos del sueño, enfermedades cardiovasculares, alteraciones del sistema inmunológico y dolencias crónicas. A nivel

psicológico, favorece el desarrollo de trastornos depresivos, ansiedad generalizada, pérdida de sentido y ruptura del vínculo identitario con el trabajo. La calidad de vida del individuo se deteriora de manera progresiva, afectando también sus relaciones personales y sociales.

4.2 Impacto en la Productividad Organizacional

Desde el punto de vista organizacional, el burnout genera un deterioro sostenido en el rendimiento laboral. Los empleados afectados presentan mayores tasas de ausentismo, reducción en la calidad de sus entregables, menor creatividad e iniciativa, y dificultades para trabajar en equipo. Esta disminución en la productividad no solo afecta los resultados individuales, sino que genera un efecto cascada sobre los equipos de trabajo y los indicadores de desempeño global de la empresa.

4.3 Costos Empresariales y Rotación de Personal

La rotación de personal asociada al burnout tiene un costo económico directo y cuantificable. Investigaciones del sector han estimado que reemplazar a un empleado puede costar entre el 50% y el 200% de su salario anual, considerando procesos de selección, capacitación, curva de aprendizaje y pérdida de conocimiento institucional. A estos costos directos se suman los costos intangibles: deterioro del clima laboral, pérdida de talento clave y daño a la reputación de la organización como empleador.

4.4 Impactos Sociales y Psicológicos

A escala social, el burnout laboral representa un problema de salud pública emergente. Su prevalencia creciente en poblaciones económicamente activas supone una presión adicional sobre los sistemas de salud, con incremento en las consultas de salud mental, incapacidades laborales y, en casos extremos, situaciones de crisis psicosocial. El bienestar psicológico de los trabajadores no es únicamente una responsabilidad individual, sino también un bien social que las organizaciones y los gobiernos tienen el deber de proteger.

5. Objetivo General

Analizar el comportamiento y la distribución de la puntuación de agotamiento laboral en trabajadores expuestos a entornos de alta integración de inteligencia artificial,

identificando los factores laborales, tecnológicos y demográficos que se asocian con mayores niveles de burnout.

6. Objetivos Específicos

1. Realizar un análisis exploratorio de datos exhaustivo del dataset seleccionado, identificando distribuciones, valores atípicos, datos faltantes y relaciones bivariadas entre las variables disponibles.
2. Identificar las variables con mayor poder explicativo sobre la tasa de burnout mediante técnicas de análisis de correlación, selección de características e importancia de variables en modelos de machine learning.
3. Pre Procesar y transformar el conjunto de datos, aplicando técnicas de codificación de variables categóricas, normalización y manejo de datos nulos, garantizando la calidad del conjunto de entrenamiento.
4. Interpretar los resultados del modelo en términos organizacionales y de bienestar laboral, generando recomendaciones prácticas que permitan a las empresas diseñar estrategias de intervención preventiva basadas en evidencia.

7. STAKEHOLDERS INTERNOS

1. Dirección y Alta Gerencia

Son quienes autorizan el proyecto, asignan presupuesto y toman decisiones estratégicas basadas en los resultados del modelo predictivo.

CEO / Gerente General: Interesado en reducir costos de rotación y mejorar la reputación organizacional como empleador responsable.

CFO / Director Financiero: Evalúa el retorno sobre la inversión del proyecto; cuantifica el ahorro derivado de reducir la rotación de personal.

COO / Director de Operaciones: Interesado en mantener la continuidad operativa y evitar interrupciones por ausentismo o renuncias inesperadas.

2. Área de Recursos Humanos

Son los usuarios finales más directos del modelo. Lo utilizarán para tomar decisiones sobre bienestar, retención y gestión del talento.

Director de RRHH: Define las políticas de intervención que se diseñarán a partir de los perfiles de riesgo que genere el modelo.

Business Partner de RRHH: Traduce los resultados del modelo en acciones concretas por área o equipo de trabajo.

Analista de Clima Organizacional: Usa las variables del dataset (satisfacción, fatiga mental) para cruzarlas con encuestas internas y validar hallazgos.

Especialista en Bienestar Laboral: Diseña programas de intervención dirigidos a los grupos identificados como de alto riesgo.

Coordinador de Selección y Retención: Utiliza las predicciones para priorizar planes de sucesión y retención en perfiles críticos.

3. Equipo de Analítica y Tecnología

Responsables del desarrollo técnico, implementación y mantenimiento del modelo predictivo.

Data Scientist / Analista de Datos: Diseña, entrena y valida los modelos de machine learning sobre el dataset.

Data Engineer: Construye los pipelines de datos que alimentan el modelo desde los sistemas internos de la organización.

Científico de Datos Junior / Practicante: Apoya en la limpieza de datos, análisis exploratorio y documentación del proceso.

Arquitecto de Soluciones / TI: Garantiza que el modelo se integre correctamente con los sistemas de información existentes (ERP, HRIS).

Responsable de Ciberseguridad: Asegura que los datos sensibles de empleados estén protegidos durante todo el ciclo de vida del proyecto.

4. Empleados de la Organización

Son tanto la fuente de los datos como los sujetos directamente afectados por las decisiones que derive el modelo.

Empleados operativos: Sus datos laborales y de bienestar alimentan el modelo; son los principales beneficiarios de las intervenciones preventivas.

Mandos medios / Supervisores: Reciben alertas sobre el estado de sus equipos y pueden activar acciones de contención antes de que el burnout escale.

Líderes de equipo: Pueden convertirse en agentes de cambio si el modelo los informa sobre señales tempranas de agotamiento en sus colaboradores.

Representantes sindicales o de comités de empleados: Velan por que el uso de los datos respete los derechos laborales y la privacidad de los trabajadores.

8. STAKEHOLDERS EXTERNOS

5. Entidades Regulatorias y Legales

Establecen el marco normativo dentro del cual el proyecto debe operar, especialmente en materia de privacidad de datos y salud laboral.

Superintendencia de Industria y Comercio (SIC) — Colombia: Regula el tratamiento de datos personales bajo la Ley 1581 de 2012; el proyecto debe cumplir con sus lineamientos de protección de datos.

Ministerio del Trabajo: Establece las normas sobre condiciones laborales, riesgo psicosocial y obligaciones del empleador frente al bienestar del trabajador.

ARL (Administradoras de Riesgos Laborales): Entidades que gestionan el riesgo psicosocial en las empresas; pueden ser aliadas estratégicas al valerse de los resultados del modelo para diseñar programas de prevención.

Autoridades de protección de datos personales: Supervisan que el uso de datos de empleados en modelos de IA cumpla con principios de finalidad, proporcionalidad y consentimiento informado.

6. Proveedores y Socios Tecnológicos

Aportan las herramientas, infraestructura y plataformas sobre las que se construye y despliega el modelo.

Proveedor de plataforma de datos en la nube (AWS, GCP, Azure): Suministra la infraestructura de cómputo y almacenamiento donde corre el modelo predictivo.

Proveedor de software HRIS (SAP SuccessFactors, Workday, Oracle HCM): Sistema desde el cual se extraen los datos de empleados que alimentan el modelo; su integración es crítica para la operación continua.

Consultora especializada en people analytics: Puede aportar metodología, benchmarks del sector y validación externa del modelo desarrollado.

Proveedor de herramientas de visualización (Power BI, Tableau): Facilita la presentación de los resultados del modelo a audiencias no técnicas como RRHH o gerencia.

7. Academia y Comunidad Científica

Aportan rigor metodológico, validación teórica y posibilidades de colaboración o publicación de resultados.

Investigadores en psicología organizacional y salud ocupacional: Validan que las variables del modelo y sus interpretaciones sean coherentes con la evidencia científica sobre burnout.

Grupos de investigación en ciencia de datos aplicada: Pueden colaborar en la mejora del modelo, la aplicación de nuevas técnicas o la publicación de hallazgos.

Universidades con programas de analítica y RRHH: Potenciales aliadas para financiamiento, pasantías o proyectos de grado articulados al proyecto.

8. Clientes y Mercado (si la solución se escala como producto)

Si el modelo evoluciona hacia un producto o servicio de people analytics, surgen nuevos stakeholders externos.

Empresas del sector tecnológico y BPO: Sectores con alta rotación y carga mental, con mayor propensión a adoptar soluciones de este tipo.

Startups de HR Tech: Potenciales aliadas o competidoras en el ecosistema de soluciones de analítica de personas.

Fondos de inversión en tecnología de RRHH: Interesados en el potencial comercial y escalabilidad del modelo si se convierte en un producto SaaS.

9. Fuente del Dataset

El Dataset fue extraído de la plataforma “Kaggle”, donde el título del mismo es “Ai Worker Risk” [DataSet]

10. Definición de tipos de datos

```python
# Definición de tipos de datos
print("Tipos de datos por columna:")
print(df.dtypes)
print("\n" + "="*80)

# Crear tabla de tipos de datos
tipos_datos = pd.DataFrame({
    'Columna': df.columns,
    'Tipo de Dato': df.dtypes.values,
    'Tipo Python': df.dtypes.apply(lambda x: str(x)).values
})

print("\nResumen de tipos de datos:")
print(tipos_datos)
```

```
Resumen de tipos de datos:
                      Columna Tipo de Dato Tipo Python
0                 employee_id          str         str
1                    job_role          str         str
2           years_experience        int64       int64
3             education_level          str         str
4                     country          str         str
5                    industry          str         str
6                company_size          str         str
7           remote_work_type          str         str
8                   team_size        int64       int64
9                salary_usd_k        int64       int64
10            primary_ai_tool          str         str
11      ai_tools_used_per_day        int64       int64
12  hours_with_ai_assistance_daily      float64     float64
13       ai_replaces_my_tasks_pct        int64       int64
14             ai_adoption_stage          str         str
15       weekly_ai_upskilling_hrs      float64     float64
16            productivity_score        int64       int64
17                 burnout_score        int64       int64
18          job_satisfaction_1_5      float64     float64
19        fear_of_ai_replacement          str         str
20                 attrition_risk          str         str
```

11. Categorización de campos

```python
# Categorización de campos
categorias = {
    'Categórico Nominal': ['employee_id', 'job_role', 'country', 'industry', 'primary_ai_tool', 'remote_work_type'],
    'Categórico Ordinal': ['education_level', 'ai_adoption_stage', 'fear_of_ai_replacement'],
    'Categórico Binario': ['attrition_risk'],
    'Numérico Discreto': ['years_experience', 'company_size', 'team_size', 'ai_tools_used_per_day'],
    'Numérico Continuo': ['salary_usd_k', 'hours_with_ai_assistance_daily', 'ai_replaces_my_tasks_pct',
                          'weekly_ai_upskilling_hrs', 'productivity_score', 'burnout_score',
                          'job_satisfaction_1_5']
}

print("CATEGORIZACIÓN DE CAMPOS DEL DATASET:\n")
for categoria, campos in categorias.items():
    print(f"\n{categoria}:")
    for campo in campos:
        if campo in df.columns:
            print(f"  ✓ {campo}")

# Crear tabla de categorización
categorias_list = []
for categoria, campos in categorias.items():
    for campo in campos:
        if campo in df.columns:
            categorias_list.append({
                'Campo': campo,
                'Categoría': categoria,
                'Tipo Dato': df[campo].dtype
            })
```

```
Tabla de Categorización:
                                Campo           Categoría Tipo D
0                         employee_id  Categórico Nominal
1                            job_role  Categórico Nominal
2                             country  Categórico Nominal
3                            industry  Categórico Nominal
4                     primary_ai_tool  Categórico Nominal
5                    remote_work_type  Categórico Nominal
6                     education_level  Categórico Ordinal
7                    ai_adoption_stage  Categórico Ordinal
8              fear_of_ai_replacement  Categórico Ordinal
9                      attrition_risk  Categórico Binario
10                   years_experience   Numérico Discreto     i
11                       company_size   Numérico Discreto
12                          team_size   Numérico Discreto     i
13              ai_tools_used_per_day   Numérico Discreto     i
14                       salary_usd_k   Numérico Continuo     i
15  hours_with_ai_assistance_daily   Numérico Continuo   flo
16          ai_replaces_my_tasks_pct   Numérico Continuo     i
17          weekly_ai_upskilling_hrs   Numérico Continuo   flo
18                productivity_score   Numérico Continuo     i
19                       burnout_score   Numérico Continuo     i
20              job_satisfaction_1_5   Numérico Continuo   flo
```

12. Cantidad de filas, columnas y elementos del dataset

```python
# Cantidad de filas usando len()
filas_len = len(df)
print(f"\n1. Cantidad de filas usando len(): {filas_len}")

# Cantidad de filas usando shape
filas_shape = df.shape[0]
print(f"2. Cantidad de filas usando shape: {filas_shape}")

# Cantidad de columnas
columnas = df.shape[1]
print(f"3. Cantidad de columnas: {columnas}")

# Cantidad total de elementos
elementos_totales = df.shape[0] * df.shape[1]
print(f"4. Cantidad total de elementos (filas × columnas): {elementos_totales}")
```

```
1. Cantidad de filas usando len(): 1500
2. Cantidad de filas usando shape: 1500
3. Cantidad de columnas: 21
4. Cantidad total de elementos (filas × columnas): 31500
```

13. Eliminación de campos no necesarios

```python
# Limpieza de datos
print("ANÁLISIS DE LIMPIEZA DE DATOS\n")
print("="*80)

# Verificar valores nulos
print("\n1. Valores nulos por columna:")
nulos = df.isnull().sum()
print(nulos[nulos > 0])
if nulos.sum() == 0:
    print("   ✓ No hay valores nulos en el dataset")

# Verificar duplicados
print(f"\n2. Filas duplicadas: {df.duplicated().sum()}")

# Identificar campos innecesarios (opcional)
print("\n3. Campos identificados como potencialmente innecesarios:")
print("   * 'employee_id': Identificador único (puede ser innecesario para análisis)")

# Crear una copia sin campos innecesarios (opcional)
df_limpio = df.drop(columns=['employee_id'])
print(f"\n4. Dataset limpio creado sin campos innecesarios")
print(f"   Dimensiones antes: {df.shape}")
print(f"   Dimensiones después: {df_limpio.shape}")
```

```
1. Valores nulos por columna:
Series([], dtype: int64)
   ✓ No hay valores nulos en el dataset

2. Filas duplicadas: 0

3. Campos identificados como potencialmente innecesarios:
   * 'employee_id': Identificador único (puede ser innecesario para análisis)

4. Dataset limpio creado sin campos innecesarios
   Dimensiones antes: (1500, 21)
   Dimensiones después: (1500, 20)
```

14. Campos numéricos y no numéricos

```python
# Seleccionar campos numéricos y no numéricos
print("SELECCIÓN DE CAMPOS NUMÉRICOS Y NO NUMÉRICOS\n")
print("="*80)

# Campos numéricos
campos_numericos = df.select_dtypes(include=[np.number]).columns.tolist()
print(f"\nCampos Numéricos ({len(campos_numericos)}):")
for campo in campos_numericos:
    print(f"  • {campo}")

# Campos no numéricos
campos_no_numericos = df.select_dtypes(exclude=[np.number]).columns.tolist()
print(f"\nCampos No Numéricos ({len(campos_no_numericos)}):")
for campo in campos_no_numericos:
    print(f"  • {campo}")
```

```
Campos Numéricos (10):
  • years_experience
  • team_size
  • salary_usd_k
  • ai_tools_used_per_day
  • hours_with_ai_assistance_daily
  • ai_replaces_my_tasks_pct
  • weekly_ai_upskilling_hrs
  • productivity_score
  • burnout_score
  • job_satisfaction_1_5

Campos No Numéricos (11):
  • employee_id
  • job_role
  • education_level
  • country
  • industry
  • company_size
  • remote_work_type
  • primary_ai_tool
```

15. Estadística de los datos

15.1 Media / Promedio

```python
# Media
print("\n1. MEDIA (PROMEDIO) - Suma de valores / cantidad de elementos")
print("-" * 80)
for col in campos_numericos:
    media = df[col].mean()
    print(f"{col:40s}: {media:.4f}")
```

```
1. MEDIA (PROMEDIO) - Suma de valores / cantidad de elementos
--------------------------------------------------------------------------------
years_experience                         : 9.9473
team_size                                : 24.8127
salary_usd_k                             : 140.7340
ai_tools_used_per_day                    : 4.0560
hours_with_ai_assistance_daily           : 4.2337
ai_replaces_my_tasks_pct                 : 41.2487
weekly_ai_upskilling_hrs                 : 4.9855
productivity_score                       : 57.5433
burnout_score                            : 50.0573
job_satisfaction_1_5                     : 3.3347
```

15.2 Mediana

```python
# Mediana
print("\n2. MEDIANA - Valor central que divide los datos en dos mitades")
print("-" * 80)
for col in campos_numericos:
    mediana = df[col].median()
    print(f"{col:40s}: {mediana:.4f}")
```

```
2. MEDIANA - Valor central que divide los datos en dos mitades
--------------------------------------------------------------------------------
years_experience                         : 10.0000
team_size                                : 25.0000
salary_usd_k                             : 139.0000
ai_tools_used_per_day                    : 4.0000
hours_with_ai_assistance_daily           : 4.2000
ai_replaces_my_tasks_pct                 : 40.0000
weekly_ai_upskilling_hrs                 : 5.0000
productivity_score                       : 57.0000
burnout_score                            : 50.0000
job_satisfaction_1_5                     : 3.3000
```

15.3 Moda

```python
# Moda para campos no numéricos
print("\n3. MODA - Valor más frecuente en los datos no numéricos")
print("-" * 80)
for col in campos_no_numericos:
    moda = df[col].mode()
    if len(moda) > 0:
        print(f"{col:40s}: {moda[0]}")
```

```
3. MODA - Valor más frecuente en los datos no numéricos
--------------------------------------------------------------------------------
employee_id                              : EMP0001
job_role                                 : Software Engineer
education_level                          : Master
country                                  : France
industry                                 : Gaming
company_size                             : Mid (200-1000)
remote_work_type                         : Hybrid
primary_ai_tool                          : Midjourney
ai_adoption_stage                        : Integrating
fear_of_ai_replacement                   : Medium
attrition_risk                           : Low
```

15.4 Varianza

```python
# Varianza
print("\n1. VARIANZA - Medida de dispersión respecto a la media")
print("-" * 80)
for col in campos_numericos:
    varianza = df[col].var()
    print(f"{col:40s}: {varianza:.4f}")
```

```
1. VARIANZA - Medida de dispersión respecto a la media
--------------------------------------------------------------------------------
years_experience                         : 29.8218
team_size                                : 187.2130
salary_usd_k                             : 3566.1714
ai_tools_used_per_day                    : 3.8968
hours_with_ai_assistance_daily           : 4.6156
ai_replaces_my_tasks_pct                 : 469.0782
weekly_ai_upskilling_hrs                 : 8.4910
productivity_score                       : 115.0675
burnout_score                            : 130.8226
job_satisfaction_1_5                     : 0.4054
```

15.5 Desviación estándar

```python
# Desviación Estándar
print("\n2. DESVIACIÓN ESTÁNDAR - Raíz cuadrada de la varianza")
print("-" * 80)
for col in campos_numericos:
    desv = df[col].std()
    print(f"{col:40s}: {desv:.4f}")
```

```
2. DESVIACIÓN ESTÁNDAR - Raíz cuadrada de la varianza
--------------------------------------------------------
years_experience                         : 5.4609
team_size                                : 13.6826
salary_usd_k                             : 59.7174
ai_tools_used_per_day                    : 1.9740
hours_with_ai_assistance_daily           : 2.1484
ai_replaces_my_tasks_pct                 : 21.6582
...
weekly_ai_upskilling_hrs                 : 0.0000
productivity_score                       : 25.0000
burnout_score                            : 16.0000
job_satisfaction_1_5                     : 1.3000
```

16. Valor máximo y mínimo

```python
# Valores máximos
print("\n4. VALOR MÁXIMO por campo numérico")
print("-" * 80)
for col in campos_numericos:
    maximo = df[col].max()
    print(f"{col:40s}: {maximo:.4f}")

# Valores mínimos
print("\n5. VALOR MÍNIMO por campo numérico")
print("-" * 80)
for col in campos_numericos:
    minimo = df[col].min()
    print(f"{col:40s}: {minimo:.4f}")
```

```
4. VALOR MÁXIMO por campo numérico
--------------------------------------------------
years_experience                        : 19.0000
team_size                               : 49.0000
salary_usd_k                            : 249.0000
ai_tools_used_per_day                   : 7.0000
hours_with_ai_assistance_daily          : 8.0000
ai_replaces_my_tasks_pct                : 79.0000
weekly_ai_upskilling_hrs                : 10.0000
productivity_score                      : 95.0000
burnout_score                           : 86.0000
job_satisfaction_1_5                    : 5.0000

5. VALOR MÍNIMO por campo numérico
--------------------------------------------------
years_experience                        : 1.0000
team_size                               : 2.0000
salary_usd_k                            : 40.0000
ai_tools_used_per_day                   : 1.0000
hours_with_ai_assistance_daily          : 0.5000
ai_replaces_my_tasks_pct                : 5.0000
weekly_ai_upskilling_hrs                : 0.0000
productivity_score                      : 25.0000
burnout_score                           : 16.0000
job_satisfaction_1_5                    : 1.3000
```

17. Resumen de los datos

```python
print("RESUMEN ESTADÍSTICO COMPLETO DE CAMPOS NUMÉRICOS")
print("="*80)
print("\nstat | count | mean | std | min | 25% | 50% (mediana) | 75% | max\n")

resumen_estadistico = df_numericos.describe()
print(resumen_estadistico)

print("\n" + "="*80)
print("INTERPRETACIÓN DE LAS ESTADÍSTICAS:")
print("="*80)
print("""
- count: Número de valores no nulos
- mean: Promedio aritmético
- std: Desviación estándar (dispersión respecto a la media)
- min: Valor mínimo
- 25%: Primer cuartil (25% de los datos están por debajo)
- 50%: Mediana (50% de los datos están por debajo)
- 75%: Tercer cuartil (75% de los datos están por debajo)
- max: Valor máximo
""")
```

	years_experience	team_size	salary_usd_k	ai_tools_used_per_day
count	1500.000000	1500.000000	1500.000000	1500.00000
mean	9.947333	24.812667	140.734000	4.05600
std	5.460932	13.682582	59.717429	1.97403
min	1.000000	2.000000	40.000000	1.00000
25%	5.000000	13.000000	91.000000	2.00000
50%	10.000000	25.000000	139.000000	4.00000
75%	15.000000	36.000000	190.000000	6.00000
max	19.000000	49.000000	249.000000	7.00000

	hours_with_ai_assistance_daily	ai_replaces_my_tasks_pct
count	1500.000000	1500.000000
mean	4.233733	41.248667
std	2.148387	21.658214
min	0.500000	5.000000
25%	2.400000	22.750000
50%	4.200000	40.000000
75%	6.100000	60.000000
max	8.000000	79.000000

	weekly_ai_upskilling_hrs	productivity_score	burnout_score
count	1500.000000	1500.000000	1500.000000
mean	4.985533	57.543333	50.057333
std	2.913933	10.726952	11.437771
min	0.000000	25.000000	16.000000
25%	2.400000	50.000000	42.000000
50%	5.000000	57.000000	50.000000
75%	7.500000	65.000000	58.000000
max	10.000000	95.000000	86.000000

	job_satisfaction_1_5
count	1500.000000
mean	3.334733
std	0.636692
min	1.300000
25%	2.900000
50%	3.300000
75%	3.800000
max	5.000000

18. Gráficas de barras

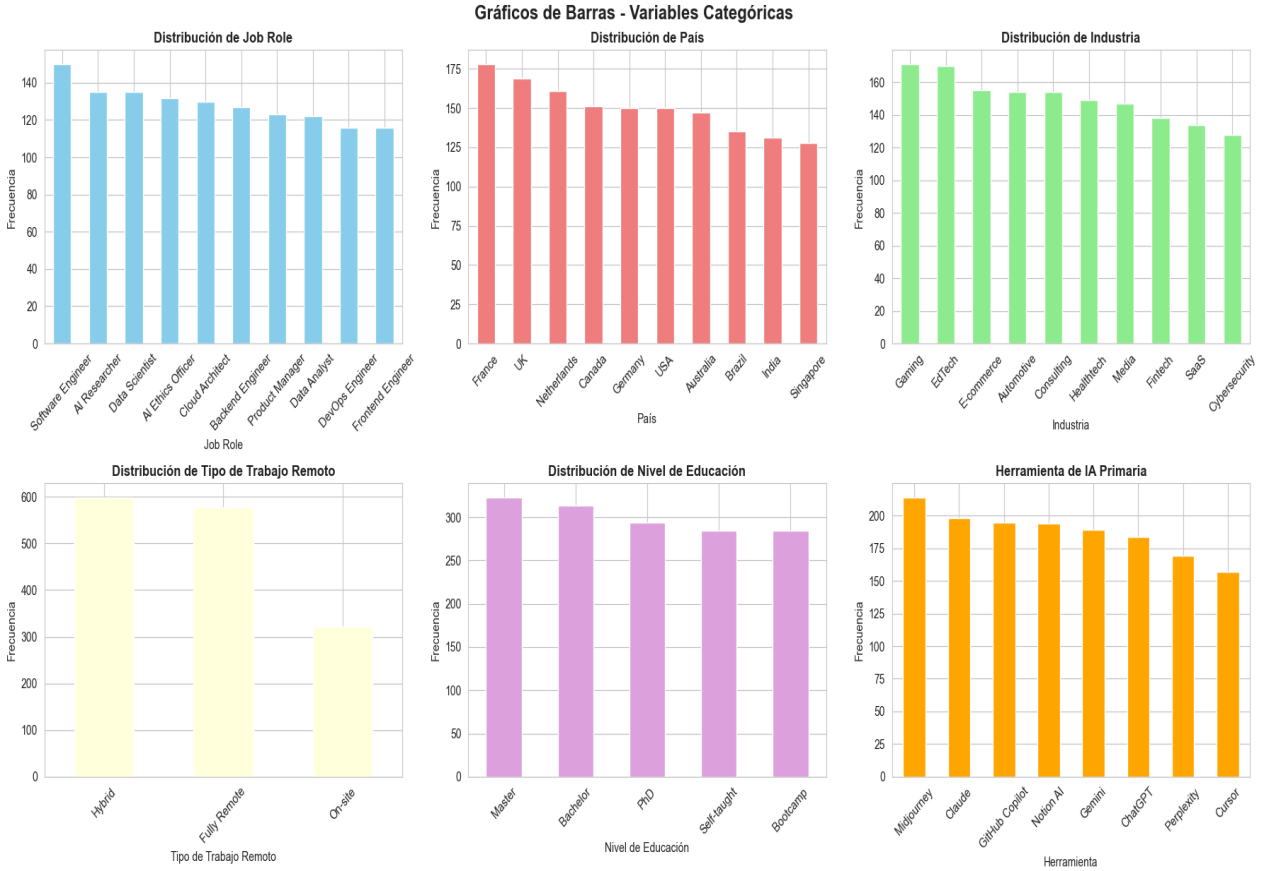

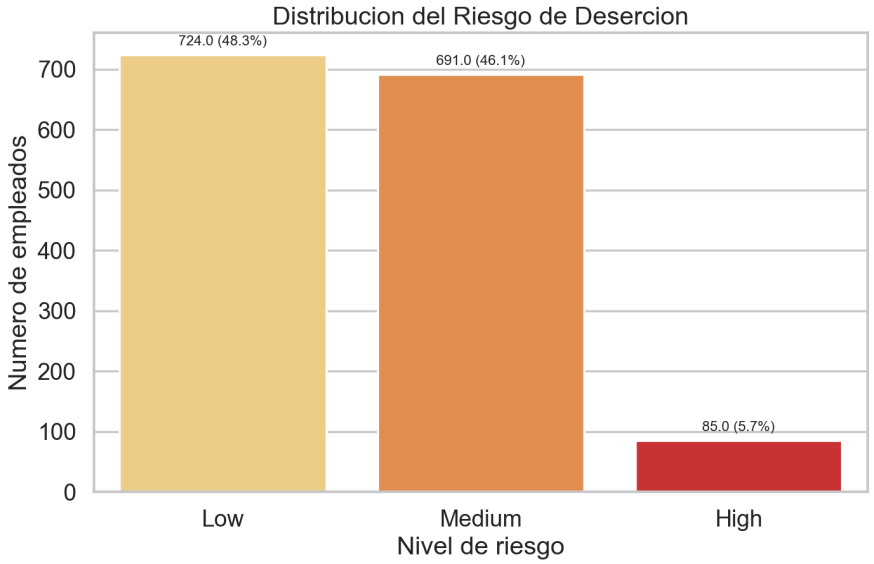

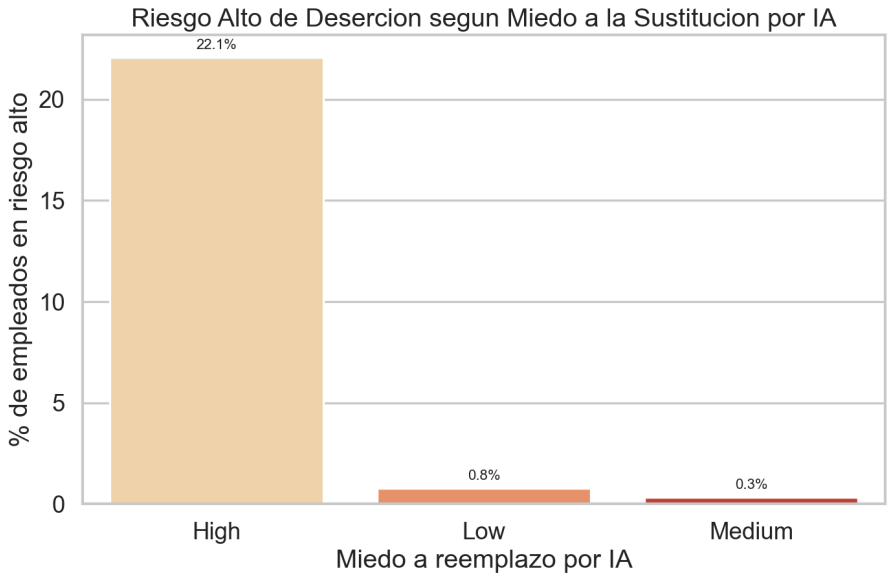

19. Gráficos de línea

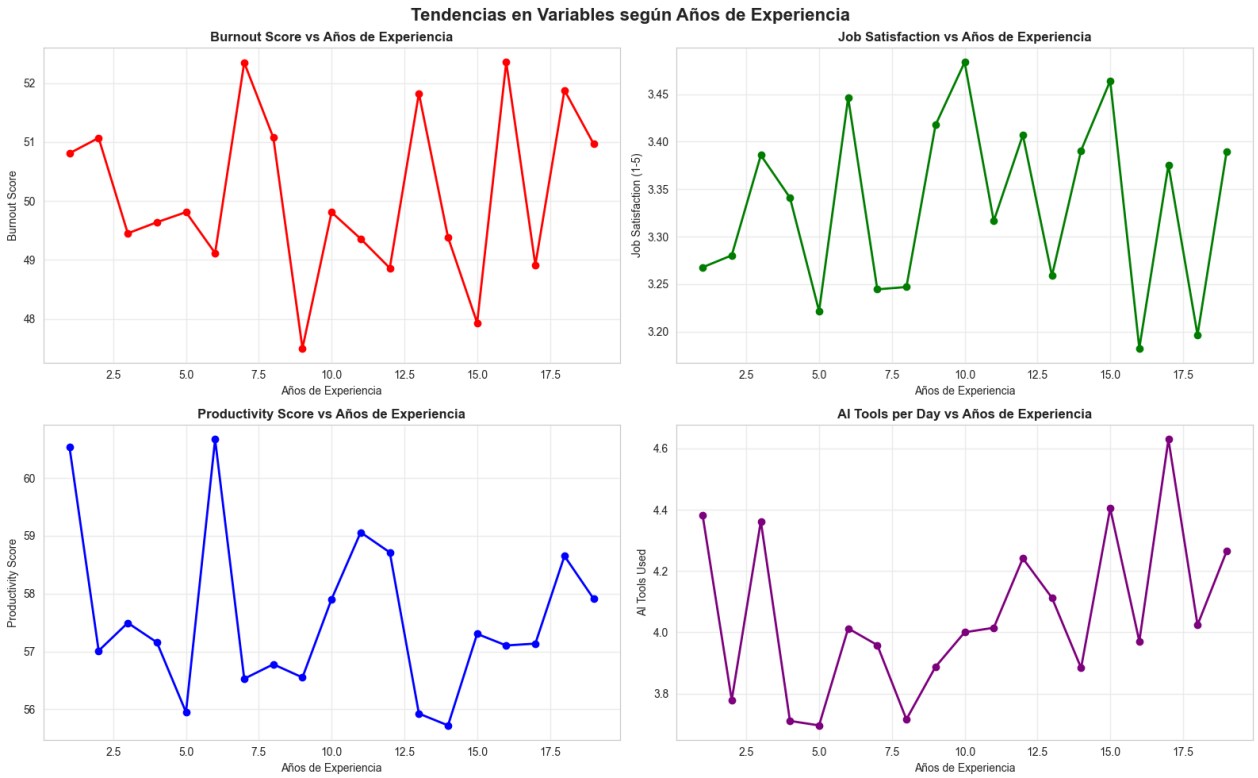

20. Gráficos de densidad/histograma.

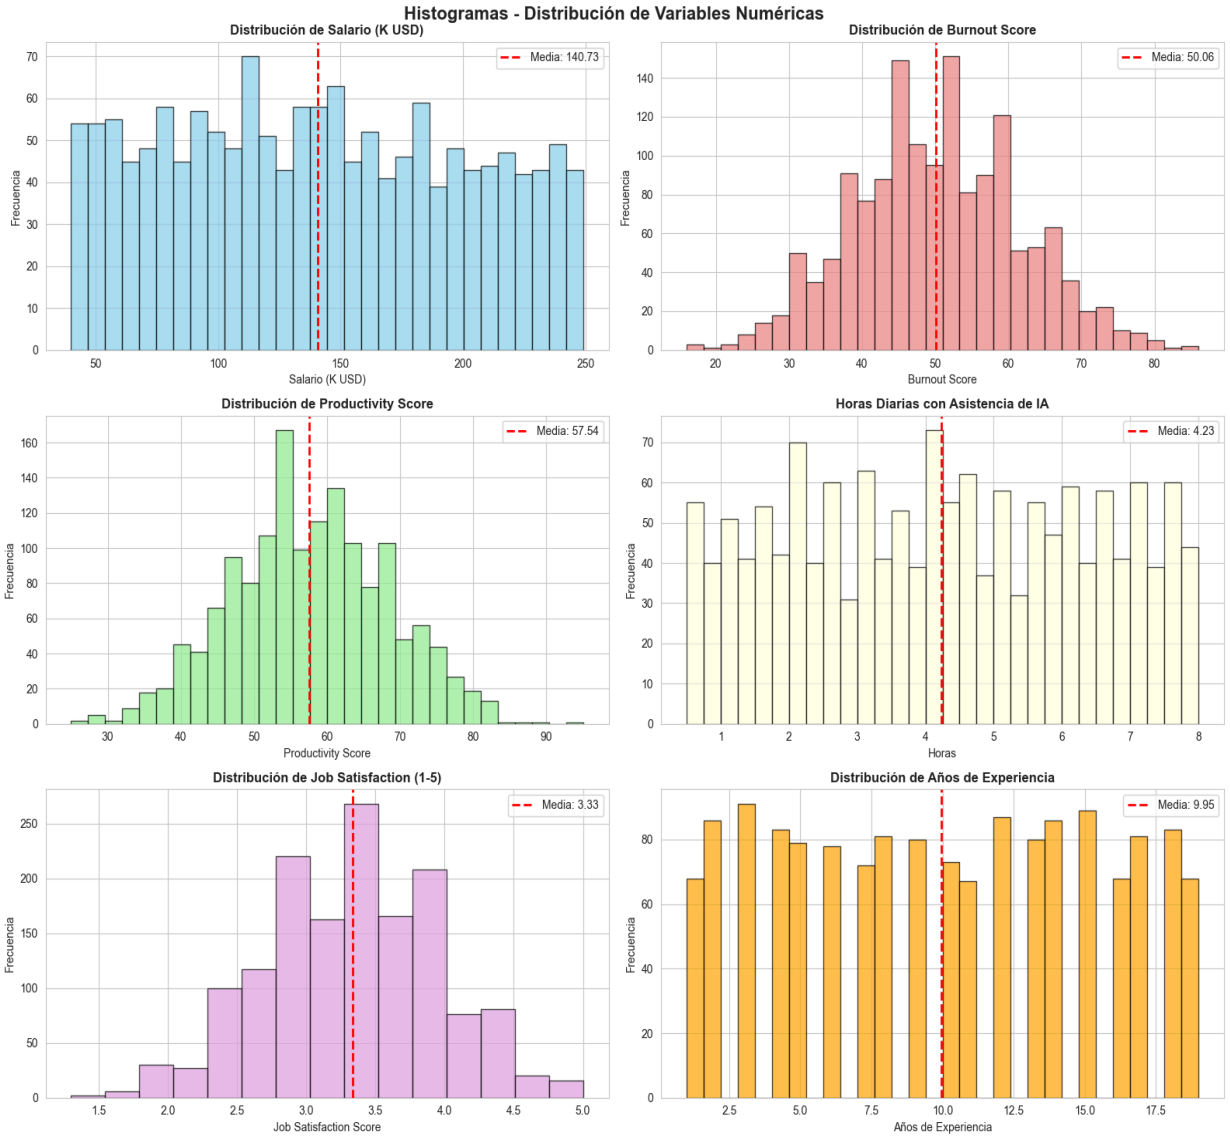

21. Gráfico dispersión

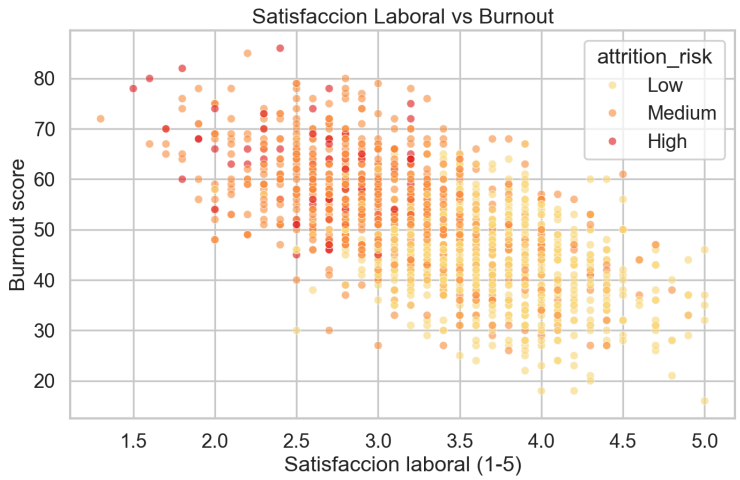

22. Gráfico mapa de calor.

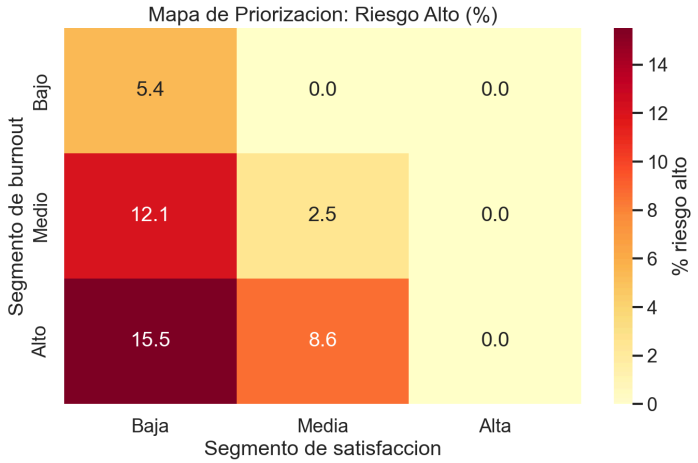

23. Gráficos de cajas y bigotes.

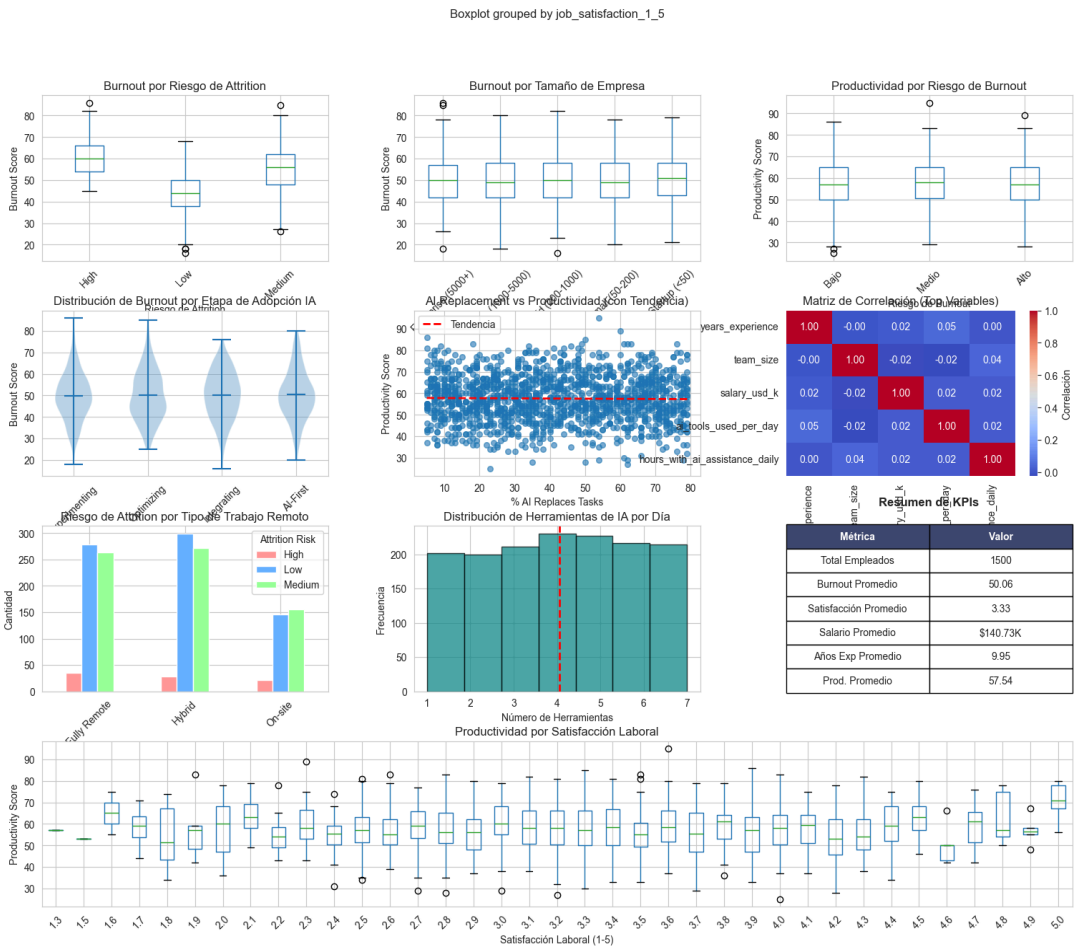

Resumen de KPIs

Métrica	Valor
Total Empleados	1500
Burnout Promedio	50.06
Satisfacción Promedio	3.33
Salario Promedio	$140.73K
Años Exp Promedio	9.95
Prod. Promedio	57.54

24. Conclusión

El burnout laboral constituye uno de los desafíos más complejos y urgentes que enfrentan las organizaciones contemporáneas. Su impacto en el bienestar de los trabajadores, la productividad empresarial y la salud pública demanda respuestas sistemáticas, informadas y oportunas. En este escenario, la analítica de datos y el aprendizaje automático ofrecen una oportunidad sin precedentes para transformar datos organizacionales dispersos en conocimiento accionable que permita anticipar, prevenir y mitigar este fenómeno.

El presente proyecto propone abordar esta problemática desde una perspectiva rigurosa y multidimensional, integrando variables laborales, demográficas y de bienestar subjetivo en modelos predictivos que puedan servir como herramientas de apoyo a la decisión en el ámbito de los recursos humanos. La capacidad de identificar con antelación a los empleados en situación de riesgo no solo representa un avance técnico, sino también un compromiso ético con la dignidad y el bienestar de las personas que conforman las organizaciones.

En definitiva, el uso inteligente de los datos al servicio del bienestar humano es, hoy más que nunca, una responsabilidad compartida entre tecnología, gestión organizacional y política pública. Este proyecto busca contribuir, desde la analítica aplicada, a la construcción de organizaciones más conscientes, resilientes y humanas.

25. Link pagina web

https://predict-my-peace.lovable.app

Referencias

Maslach, C., & Leiter, M. P. (1997). The truth about burnout: How organizations cause personal stress and what to do about it. Jossey-Bass.

Organización Mundial de la Salud. (2019). Clasificación Internacional de Enfermedades (CIE-11): Burn-out un fenómeno ocupacional. OMS.

Munishwar, K. (2024). AI Worker Risk Dataset. Kaggle. Recuperado de https://www.kaggle.com/code/kathimunishwar/ai-worker-risk

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning with applications in R (2nd ed.). Springer.

Gallup. (2023). State of the Global Workplace Report. Gallup Press.